

OPEN AI SORA 技术报告原文+译文+ 报告总结

文档整理：AI 设计研究室

<https://space.bilibili.com/2161614>

要点总结

模型路径：

1. 架构为扩散模型 (diffusion model) + transformer
2. 训练时先用预训练模型把大量的大小不一的视频源文件编码转化为统一的 patch 表示，把时空要素提取作为 transformer 的 token 进行训练。
3. 模型效果好和超大量的数据集和更多的运算时间息息相关

优势：

1. 人物和背景的连贯性，即时人物运动出了相机范围再回来时还保持同样特征
2. 自然语言的理解程度很高
3. 可以在同一个种子下生成不同尺寸（横向竖向）的视频适配不同设备
4. 可以生成长达 1min 高清视频
5. 可以以文字，图片，视频作为控制要素控制输出结果

不足：

1. 对于物理规则了解较弱，比如吹气后蜡烛不会熄灭，左右不分，玻璃掉落不会碎
2. 对于算力要求较高（猜测）

可以实现：

1. 文生视频，图生视频，图+文生视频，视频修改
2. 视频转绘，视频延伸，视频补全

未来畅想：

1. 重新洗牌 AI 生成视频产业
2. 扩散模型的上限比想象中的高！
3. 全局一致性可以被解决
4. 文字生成 3D 或将迎来突破
5. AR,VR, VisionPro 新型应用潜力

大神观点：



骆思勉 清华叉院

看完Technical Report的一些想法：

1. Diffusion生成框架的天花板远比我们之前想象的要更高(很可能已经够了), make diffusion great again! 给Diffusion研究者注入一剂强心剂💪。从数学理论上来说, Diffusion也是能够几乎拟合任意数据分布的(包括真实世界的连贯性视频)。

2. Scale is all you need. Scale上去后, 在视频生成上能够产生类似在LLM里的涌现现象。包括视频连贯性, 3D consistency, Long-range coherence。

3. Physics Prior什么的可能都不需要额外引入。Scale + Data足以。