

OPEN AI SORA 技术报告原文+译文+ 报告总结

文档整理：AI 设计研究室

<https://space.bilibili.com/2161614>

要点总结

模型路径：

1. 架构为扩散模型（diffusion model）+transformer
2. 训练时先用预训练模型把大量的大小不一的视频源文件编码转化为统一的 patch 表示，把时空要素提取作为 transformer 的 token 进行训练。
3. 模型效果好和超大量的数据集和更多的运算时间息息相关

优势：

1. 人物和背景的连贯性，即时人物运动出了相机范围再回来时还保持同样特征
2. 自然语言的理解程度很高
3. 可以在同一个种子下生成不同尺寸（横向竖向）的视频适配不同设备
4. 可以生成长达 1min 高清视频
5. 可以以文字，图片，视频作为控制要素控制输出结果

不足：

1. 对于物理规则了解较弱，比如吹气后蜡烛不会熄灭，左右不分，玻璃掉落不会碎
2. 对于算力要求较高（猜测）

可以实现：

1. 文生视频，图生视频，图+文生视频，视频修改
2. 视频转绘，视频延伸，视频补全

未来畅想：

1. 重新洗牌 AI 生成视频产业
2. 扩散模型的上限比想象中的高！
3. 全局一致性可以被解决
4. 文字生成 3D 或将迎来突破
5. AR,VR, VisionPro 新型应用潜力

大神观点：



骆思勉 清华叉院

看完Technical Report的一些想法：

1. Diffusion生成框架的天花板远比我们之前想象的要更高(很可能已经够了), make diffusion great again! 给Diffusion研究者注入一剂强心剂💪。从数学理论上来说，Diffusion也是能够几乎拟合任意数据分布的(包括真实世界的连贯性视频)。
2. Scale is all you need. Scale上去后，在视频生成上能够产生类似在LLM里的涌现现象。包括视频连贯性，3D consistency, Long-range coherence。
3. Physics Prior什么的可能都不需要额外引入。Scale + Data足以。

英文原文

中文翻译

Video generation models as world simulators

We explore large-scale training of generative models on video data. Specifically, we train text-conditional diffusion models jointly on videos and images of variable durations, resolutions and aspect ratios. We leverage a transformer architecture that operates on spacetime patches of video and image latent codes.

视频生成模型作为世界模拟器

我们探索了在视频数据上进行大规模生成模型的训练。具体而言，我们联合在可变持续时间、分辨率和宽高比的视频和图像上训练了文本条件扩散模型。我们利用了一个在视频和图像潜在编码的时空块上操作的 transformer 架构。

Our largest model, Sora, is capable of generating a minute of high fidelity video. Our results suggest that scaling video generation models is a promising path towards building general purpose simulators of the physical world.

我们最大的模型，Sora，能够生成一分钟高保真度的视频。我们的结果表明，扩展生成模型是建立通用物理世界模拟器的有前景的道路。

This technical report focuses on (1) our method for turning visual data of all types into a unified representation that enables large-scale training of generative models, and (2) qualitative evaluation of Sora’s capabilities and limitations. Model and implementation details are not included in this report.

本技术报告关注以下两个方面：(1) 我们将各种类型的视觉数据转换为统一表示的方法，以实现大规模生成模型的训练，以及 (2) 对模型的能力和局限性进行定性评估。模型和实现细节未包含在本报告中。之前的研究已经探索了使用各种方法对视频数据进行生成建模，包括循环网络、生成对抗网络、自回归变分扩散模型。这些工作通常侧重于某一类视觉数据。

Much prior work has studied generative modeling of video data using a variety of methods, including recurrent networks,^{1,2,3} autoregressive generative networks,^{4,5,6,7} autoregressive transformers,^{8,9} and diffusion models.^{10,11,12} These works often focus on a narrow category of visual data, on shorter videos, or on videos of a fixed size. Sora is a generalist model of visual data—it can generate videos and images spanning diverse durations, aspect ratios and resolutions, up to a full minute of high definition video.

我们探索了将各种视觉数据转换为一种通用模型——它支持任意持续时间、宽高比和分辨率的高清视频，最长可达一分钟。

Turning visual data into patches

将视觉数据转换成 patch

We take inspiration from large language models which acquire generalist capabilities by training on internet-scale data.^{13,14} The success of the LLM paradigm is enabled in part by the use of tokens that elegantly unify diverse modalities of text—code, math and various natural languages. In this work, we

我们受到大型语言模型的启发，在互联网规模的数据上进行训练。LLM 范式成功部分归功于文本的多种模态——代码、数学和自然语言的标记。在这项工作中，我们考虑如何将视觉数据模型如何继承这些好处。而 LLMs 具有文本标记，Sora 具有视觉 patch。patch 已被证明是视觉数据模型的有效表示。

consider how generative models of visual data can inherit such benefits. Whereas LLMs have tokens, Sora has visual patches. Patches have previously been

成视觉数据模型如何继承这些好处。而 LLMs 具有文本标记，Sora 具有视觉 patch。patch 已被证明是视觉数据模型的有效表示。